

YazLab 2. Proje Raporu

Deney Sonuçları ve Karşılaştırmalı Analiz Tabloları

Kaan Albayrak (211307020)

Grup No: 37

Giriş

Bu doküman, "From Black-Box to Explainability: Probabilistic Automata for Time Series Analysis" başlıklı projenin kapsamlı deney sonuçlarını ve detaylı tablo dökümlerini içermektedir. Proje kapsamında, iki farklı veri seti (SKAB ve BATADAL) üzerinde üç model (LSTM, GRU, Probabilistic Automata) beş farklı random seed [42, 123, 2026, 7, 999] ile test edilerek analiz edilmiştir.

- Veri Setleri:** SKAB (valve1 + valve2 klasörleri birleştirilmiş, 22.472 satır, %34.8 anomali yoğunluğu) ve BATADAL Training Dataset 2 (4.177 satır, %5.2 saldırı yoğunluğu, hedef değişken: ATT_FLAG).
- Değerlendirme Stratejisi:** SKAB için dosya bazlı veri sızıntısını önlemek amacıyla Stratified GroupKFold (k=5, grup: source_file) uygulanmıştır. BATADAL için zaman sırası korunarak %60 eğitim, %20 doğrulama ve %20 test bölme stratejisi kullanılmıştır.

1. Temel Performans ve Stabilité

Modellerin iki veri seti üzerindeki ortalama performans metrikleri ve 5 farklı random seed ile elde edilen standart sapma (std) değerleri aşağıda sunulmaktadır.

Model	SKAB F1 $\pm$ std	SKAB Acc.	SKAB Prec.	SKAB Rec.	BATADAL F1 $\pm$ std	BATADAL Acc.	BATADAL Prec.	BATADAL Rec.
LSTM	0.796 $\pm$ 0.065	0.851 $\pm$ 0.050	0.783 $\pm$ 0.097	0.822 $\pm$ 0.095	0.212 $\pm$ 0.308	0.910 $\pm$ 0.028	0.301 $\pm$ 0.333	0.180 $\pm$ 0.282
GRU	0.829 $\pm$ 0.079	0.878 $\pm$ 0.059	0.830 $\pm$ 0.100	0.840 $\pm$ 0.102	0.009 $\pm$ 0.018	0.897 $\pm$ 0.004	0.036 $\pm$ 0.073	0.005 $\pm$ 0.010
Automata	0.103 $\pm$ 0.066	0.598 $\pm$ 0.025	0.232 $\pm$ 0.159	0.067 $\pm$ 0.043	0.171 $\pm$ 0.000	0.860 $\pm$ 0.000	0.188 $\pm$ 0.000	0.158 $\pm$ 0.000

Not: BATADAL veri setindeki yüksek LSTM standart sapma değeri (0.308), derin öğrenme modellerinin veri kısıtlılığı ve aşırı sınıf dengesizliği altında başlangıç seed değerine karşı ne kadar hassas ve kararsız davrandığını ortaya koymaktadır. Buna karşın Olasılıksal Automata modeli tamamen deterministik bir yapı sunarak sıfır varyans (std=0.000) ile kararlı bir duruş sergilemiştir.

2. Gürültü ve Unseen Veri Analizi (Robustness)

Modellerin gürültülü veri (Gaussian noise, $\sigma=0.05$) ve test kümesinde yer alan ancak eğitim sözlüğünde bulunmayan örüntüler (unseen veri) altındaki dayanıklılığı test edilmiştir. Unseen senaryoları için tespit oranı (Detection Rate - Recall) ve eşleme doğruluğu (Mapping Accuracy - Precision) hesaplanmıştır.

Tablo 2a: Gürültü Etkisi ve Unseen Senaryo - SKAB

Model	Orijinal F1	Gürültülü F1	Δ Gürültü	Unseen Det. Rate (Recall)	Unseen Map. Acc. (Precision)
LSTM	0.796	0.794	-0.002	0.892	0.908
GRU	0.829	0.832	+0.003	0.935	0.924
Automata	0.103	0.058	-0.045	0.026	0.448

Tablo 2b: Gürültü Etkisi ve Unseen Senaryo - BATADAL

Model	Orijinal F1	Gürültülü F1	Δ Gürültü	Unseen Det. Rate (Recall)	Unseen Map. Acc. (Precision)
LSTM	0.212	0.211	-0.001	0.000	0.000
GRU	0.009	0.009	0.000	0.000	0.000
Automata	0.171	0.053	-0.118	0.000	0.000

Yorum: Derin öğrenme modelleri gürültüye karşı yüksek direnç gösterirken ($\Delta \approx 0$), Automata modeli SAX kuantizasyonunun gürültüye olan hassasiyeti sebebiyle F1 skorunda düşüş yaşamıştır. BATADAL unseen test senaryosundaki tüm değerlerin 0.000 çıkması, zaman sıralı test kümesinin son %10'luk kesitinde hiç anomali/saldırı verisinin yer almamasından kaynaklanmaktadır.

3. Veri Seti Karakteristiği Karşılaştırma

Modellerin performanslarının veri setlerinin yapısal özelliklerine (anomali oranları, sınıf dengesizliği seviyeleri) olan bağımlılığı analiz edilmiştir.

Model	SKAB F1 (Dengeli - %34.8)	BATADAL F1 (Aşırı Dengesiz - %5.2)	Performans Farkı (Δ)	SKAB Kararlılık (std)	BATADAL Kararlılık (std)
LSTM	0.796	0.212	-0.584	0.065	0.308
GRU	0.829	0.009	-0.820	0.079	0.018
Automata	0.103	0.171	+0.068	0.066	0.000

Değerlendirme: Derin öğrenme modelleri, görece dengeli anomali dağılımına sahip sinyallerde (SKAB) üstün başarı gösterirken, aşırı sınıf dengesizliği içeren sistemlerde (BATADAL) anomaliyi tamamen göz ardı ederek kolayca kaçma eğilimi (tüm sınıfları normal tahmin etme) göstermiştir. Olasılıksal Automata ise sınıf dengesizliğine karşı yüksek yapısal dirence sahiptir; SKAB veri setindeki karmaşık bağımlılıklar nedeniyle "yutucu durum (absorbing state)" problemine takılrsa da BATADAL veri setinde derin öğrenme alternatiflerine kıyasla çok daha dengeli ve güvenilir bir metrik profili çizmiştir.

4. Automata Parametre ve Süre Analizi

4.1 Parametre Duyarlılık Analizi

Pencere boyutu (ws) ve alfabe boyutu (ab) değişimlerinin model performansı, durum (state) sayısı ve geçiş yoğunluğu üzerindeki etkileri kapsamlı bir şekilde izlenmiştir.

Tablo 4a: BATADAL Veri Seti Parametre Süpürme (Sweep) Özeti

Pencere Boyutu (ws)	Alfabe Boyutu (ab)	Ortalama F1	Durum Sayısı (State)	Geçiş Yoğunluğu
3	3	0.154	9	0.321
3	6	0.113	36	0.110
4 (Sabit Kriter)	3 (Sabit Kriter)	0.171	9	0.333
4	4	0.133	16	0.207
5	5	0.174	24	0.144
6 (Optimum ws)	4 (Optimum ab)	0.240	16	0.215
6	6	0.203	36	0.098

Tablo 4b: SKAB Veri Seti Parametre Süpürme (Sweep) Özeti

Pencere Boyutu (ws)	Alfabe Boyutu (ab)	Ortalama F1	Durum Sayısı (State)	Geçiş Yoğunluğu
3	3	0.038	9	0.272
3	6	0.087	27	0.133
4 (Sabit Kriter)	3 (Sabit Kriter)	0.065	9	0.259
4	4	0.093	13	0.207
5 (Optimum ws)	4 (Optimum ab)	0.103	12	0.222
6	4	0.078	12	0.201
6	6	0.089	23	0.138

Parametre Çıkarımı: Alfabe boyutu (ab) arttıkça sembolik çeşitlilik genişlemekte ve durum sayısı monoton olarak artış göstermektedir. Ancak bu durum geçiş matrisinin seyrekleşmesine (sparsity) ve geçiş yoğunluğunun düşmesine neden olarak F1 skorunu negatif etkileyebilmektedir. En dengeli kombinasyonlar BATADAL için ws=6, ab=4 (F1=0.240) ve SKAB için ws=5, ab=4 (F1=0.103) olarak saptanmıştır.

4.2 Modellerin Çalışma Süresi (Runtime) Karşılaştırması

Tablo 5a: SKAB Veri Seti Çalışma Süreleri Karşılaştırması

Model	Ortalama Eğitim Süresi (1 Fold)	Ortalama Çıkarım Süresi (Test)	Toplam Süre (5 seed × 5 fold / 25 Run)
LSTM	6.25 dakika	5.77 saniye	156.33 dakika
GRU	5.85 dakika	5.16 saniye	146.25 dakika
Automata	~1.85 saniye	~0.08 saniye	~46.25 saniye

Tablo 5b: BATADAL Veri Seti Çalışma Süreleri Karşılaştırması

Model	Ortalama Eğitim Süresi (1 Fold)	Ortalama Çıkarım Süresi (Test)	Toplam Süre (5 seed × 5 fold / 25 Run)
LSTM	1.13 dakika	3.42 saniye	28.42 dakika
GRU	1.05 dakika	3.02 saniye	26.25 dakika
Automata	~0.35 saniye	~0.02 saniye	~8.75 saniye

Yorum: Olasılıksal Automata modeli, derin öğrenme tabanlı yaklaşımlara göre eğitim sürelerinde daha hızlı sonuçlanarak operasyonel ve donanımsal açıdan muazzam bir verimlilik avantajı sunmaktadır.

5. İstatistiksel Anlamlılık Analizi

Modeller arasındaki performans farklarının şans eserinden uzak olup olmadığını belirlemek adına per-seed F1 skorları üzerinden Wilcoxon Signed-Rank testi koşturulmuştur.

Karşılaştırma Çifti	SKAB (Statistic)	SKAB (p-value)	BATADAL (Statistic)	BATADAL (p-value)	Anlamlı mı? ($\alpha=0.05$)
LSTM vs Automata	0.0	0.0625	3.0	0.3125	Hayır
GRU vs Automata	0.0	0.0625	0.0	0.0625	Hayır
LSTM vs GRU	0.0	0.0625	0.0	0.0625	Hayır

Değerlendirme: Elde edilen tüm p-değerleri anlamlılık eşiği olan $\alpha=0.05$ 'ten büyük çıkmıştır. Modeller arasındaki ham skor farkları gözlemsel olarak çok bariz (örn. SKAB: GRU 0.829 vs Automata 0.103) olsa da, testin $n=5$ tohum veri (seed count) gibi düşük örneklem büyüklüğü ile yürütülmesi, istatistiksel gücün (statistical power) yetersiz kalmasına sebebiyet vermiş ve hipotez teyidini engellemiştir.

6. Olasılıksal Açıklanabilirlik Örneği

Otomata modelinin iç mekanizmasından çekilmiş, anomali tespit edilen spesifik bir karara ait açıklama adımı (t=7 adımı):

Tablo 7: Sistem Karar Formatı

Bileşen Sütunu	Açıklama Alanı	Adım Çıktı Değeri (t=7)
time_step	İşlem zaman adımı	7
state	Mevcut otomata durumu	"aa"
pattern	Gözlemlenen ham SAX pattern	"aa"
status	Sözlük kontrol durumu	"seen"
mapped_to	Vocabulary eşleşmesi	"aa"
transitions	Aktif durum geçiş haritası ve olasılığı	{"aa -> ab": 0.100000}
path_probability	Birikimli geçiş olasılıkları çarpımı	6.3e-05
decision	Nihai sistem kararı	"anomaly"
confidence_score	Model güven ve kanıt skoru	0.1 (Low)

```
[SYSTEM DECISION LOG - TIME STEP 7]
-----
Time Step: 7
Previous State: "aa"
Incoming Pattern: "aa"
Status: seen
Mapped To: "aa"

Transitions:
  aa -> ab : 0.100000

Path Probability: 0.000063
Decision: ANOMALY
Confidence Score: 0.1 (Low probability path detected)
-----
```

7. Genel Bulgular ve Kapanış


Dengeli anomali senaryolarında derin öğrenme modelleri (özellikle GRU ve LSTM) sekanslar arası korelasyonları başarıyla yakalayarak oldukça yüksek doğruluk değerlerine ulaşmaktadır. Ancak aşırı sınıf dengesizliğinin, model güvenilirliğinin ve kararların şeffaf bir şekilde gerekçelendirilmesinin (XAI) öncelikli olduğu kritik endüstriyel altyapılarda, Olasılıksal Automata yaklaşımı hafif, açıklanabilir, kararlı ve hızlı bir alternatif mimari olarak öne çıkmaktadır.

8. Görseller ve Grafik Çıktılar


Bu bölümde modellerin performansına ilişkin tüm görsel çıktıları sunulmaktadır: Confusion Matrix, ROC / Precision-Recall eğrileri, Otomata durum diyagramları, geçiş olasılığı ısı haritaları ve parametre analizi grafikleri.

8.1 Confusion Matrix Grafikleri


SKAB Veri Seti



Şekil 1: LSTM — SKAB Confusion Matrix




Şekil 2: GRU — SKAB Confusion Matrix




Şekil 3: Automata — SKAB Confusion Matrix


BATADAL Veri Seti



Şekil 4: LSTM — BATADAL Confusion Matrix




Şekil 5: GRU — BATADAL Confusion Matrix




Şekil 6: Automata — BATADAL Confusion Matrix

8.2 ROC Eğrileri

SKAB Veri Seti




Şekil 7: LSTM ROC — SKAB (AUC=0.952)




Şekil 8: GRU ROC — SKAB (AUC=0.936)

BATADAL Veri Seti




Şekil 9: LSTM ROC — BATADAL (AUC=0.934)




Şekil 10: GRU ROC — BATADAL

8.3 Precision-Recall Eğrileri

SKAB Veri Seti




Şekil 11: LSTM PR — SKAB (AP=0.941)




Şekil 12: GRU PR — SKAB

BATADAL Veri Seti




Şekil 13: LSTM PR — BATADAL (AP=0.424)




Şekil 14: GRU PR — BATADAL

8.4 Otomata Durum Diyagramları




Şekil 15: Probabilistic Automata Durum Diyagramı — SKAB (ws=4, ab=3, 9 durum)




Şekil 16: Probabilistic Automata Durum Diyagramı — BATADAL (ws=4, ab=3, 9 durum)

8.5 Geçiş Olasılığı Isı Haritaları




Şekil 17: Geçiş Olasılığı Isı Haritası — SKAB




Şekil 18: Geçiş Olasılığı Isı Haritası — BATADAL

8.6 Parametre Analizi — Durum Sayısı ve Geçiş Yoğunluğu



Şekil 19: Durum Sayısı ve Geçiş Yoğunluğu Analizi — SKAB ($ws \in \{3,4,5,6\} \times ab \in \{3,4,5,6\}$)



Şekil 20: Durum Sayısı ve Geçiş Yoğunluğu Analizi — BATADAL ($ws \in \{3,4,5,6\} \times ab \in \{3,4,5,6\}$)

Kaynaklar

- [1] SKAB — Skoltech Anomaly Benchmark (Veri seti kaynağı)

<https://github.com/waico/SKAB/tree/master>

- [2] BATADAL — Battle of the Attack Detection Algorithms (Veri seti kaynağı)

<https://www.batadal.net/data.html>

- [3] GeeksforGeeks — What is Data Normalization?

<https://www.geeksforgeeks.org/machine-learning/what-is-data-normalization/>

- [4] GeeksforGeeks — Data Normalization with Pandas

<https://www.geeksforgeeks.org/python/data-normalization-with-pandas/>

- [5] CodeSignal — Standardizing and Normalizing Data in Python

<https://codesignal.com/learn/courses/introduction-to-data-cleaning-with-python/lessons/standardizing-and-normalizing-data-in-python>

- [6] GeeksforGeeks — Principal Component Analysis with Python

<https://www.geeksforgeeks.org/data-analysis/principal-component-analysis-with-python/>

- [7] Scikit-learn — sklearn.decomposition.PCA (API Dokümantasyonu)

<https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>

- [8] DataCamp — Principal Component Analysis in Python

<https://www.datacamp.com/tutorial/principal-component-analysis-in-python>

- [9] GeeksforGeeks — Introduction to Long Short-Term Memory (LSTM)

<https://www.geeksforgeeks.org/deep-learning/deep-learning-introduction-to-long-short-term-memory/>

- [10] Machine Learning Mastery — Time Series Prediction with LSTM in Python/Keras

<https://machinelearningmastery.com/time-series-prediction-lstm-recurrent-neural-networks-python-keras/>

- [11] Medium — Creating an LSTM Model in Python

<https://medium.com/@techwithjules/recurrent-neural-networks-rnns-and-long-short-term-memory-lstm-creating-an-lstm-model-in-13c88b7736e2>

- [12] DataCamp — LSTM Models Tutorial

<https://www.datacamp.com/tutorial/lstm-models>

- [13] GeeksforGeeks — Gated Recurrent Unit (GRU) Networks

<https://www.geeksforgeeks.org/machine-learning/gated-recurrent-unit-networks/>

- [14] Towards Data Science — GRU Recurrent Neural Networks: Predict Sequences in Python

<https://towardsdatascience.com/gru-recurrent-neural-networks-a-smart-way-to-predict-sequences-in-python-80864e4fe9f6/>

- [15] PyTorch Docs — torch.nn.GRU

<https://docs.pytorch.org/docs/2.12/generated/torch.nn.GRU.html>

- [16] Kaggle — Intro to Recurrent Neural Networks: LSTM & GRU

<https://www.kaggle.com/code/thebrownvikings/intro-to-recurrent-neural-networks-lstm-gru>

- [17] Dev.to — Sliding Window: Python Data Structures and Algorithms

<https://dev.to/rishabtrivedi/sliding-window-python-data-structures-and-algorithms-16m>

- [18] GeeksforGeeks — Introduction to Python Levenshtein Module

<https://www.geeksforgeeks.org/python/introduction-to-python-levenshtein-module/>

- [19] DigitalOcean — Levenshtein Distance in Python

<https://www.digitalocean.com/community/tutorials/levenshtein-distance-python>

[20] Medium — Guide to Adding Noise to Your Data Using Python and NumPy

https://medium.com/@ms_somanna/guide-to-adding-noise-to-your-data-using-python-and-numpy-c8be815df524

[21] AALpy — Active Automata Learning Library (GitHub)

<https://github.com/DES-Lab/AALpy>